

INSTITUTO INFNET

Engenharia de Computação / Robótica com ROS 2

TERMO DE ABERTURA DE PROJETO (TAP)

Projeto ARACNE

Aplicação de Reconhecimento de Aracnídeos por Câmera em Nós Embarcados

Trabalho de Projeto - TP1 ao Assessment

Aluno: João Rafael Broz dos Santos

Professor: Dácio Moreira de Souza

Rio de Janeiro —08/2026

1. Identificação do Projeto

Campo	Descrição
Nome do projeto	ARACNE - Aplicação de Reconhecimento de Aracnídeos por Câmera em Nós Embarcados
Aluno responsável	João Rafael Broz dos Santos
Instituição	Instituto Infnet
Disciplina	Projeto de Bloco - Sistemas Robóticos
Professor orientador	Dacio Moreira de Souza
Data de abertura	28/08/2026
Ciclo de entregas	TP1 (planejamento) a ASSESSMENT (integração e defesa)
Categoria do projeto	Projeto próprio, derivado da sugestão "robô perceptivo com câmera e/ou sensores", sujeito a aprovação do professor
Versão deste documento	v1.0 - 28/08/2026

2. Contexto e Justificativa

O Brasil concentra uma das maiores diversidades de aracnídeos do mundo e, ao mesmo tempo, registra milhares de acidentes anuais envolvendo aranhas de importância médica. Grande parte da gravidade desses acidentes não decorre da picada em si, mas do atraso ou do erro na identificação do animal: o atendimento correto depende de saber, com rapidez, a que gênero pertence o exemplar encontrado. A identificação, hoje, depende de conhecimento especializado em aracnologia, que não está disponível no momento e no local em que o encontro ocorre.

Esse é um problema de percepção visual em ambiente não controlado, exatamente a classe de problema para a qual sistemas robóticos perceptivos são projetados. Um agente que observa o mundo por uma câmera, segmenta a região de interesse, extrai características e classifica o que vê reproduz, em escala reduzida, o pipeline de percepção de um robô de inspeção real.

A escolha do ROS 2 é fundamental nesse projeto. O problema é naturalmente distribuído: aquisição de imagem, pré-processamento, segmentação, extração de features e inferência são etapas com taxas de execução, custos computacionais e ciclos de vida diferentes. Modelá-las como nós independentes que se comunicam por tópicos e serviços permite (1) substituir a fonte de imagem, webcam, vídeo gravado ou câmera da Raspberry Pi, sem alterar o restante do sistema; (2) instrumentar e depurar cada etapa isoladamente com as ferramentas nativas (ros2 topic, rqt_graph, rqt_image_view); e (3) distribuir o processamento entre máquinas via DDS, caso o módulo de inferência precise migrar para outro host. Uma implementação monolítica em um único script Python não ofereceria nenhuma dessas propriedades.

Do ponto de vista acadêmico, o projeto exercita integralmente o conteúdo previsto para os TPs: comunicação publisher/subscriber, serviços, conversão de espaços de cor, segmentação, extração de features, análise do grafo de comunicação e documentação de arquitetura.

3. Objetivos

3.1. Objetivo geral

Desenvolver um sistema perceptivo baseado em ROS 2 capaz de capturar imagens de uma câmera em tempo real, segmentar e classificar aracnídeos entre quatro espécies previamente definidas e retornar a classificação taxonômica completa (reino, filo, subfilo, classe, ordem, família, gênero e espécie), o nome popular e as características descritivas do exemplar identificado.

3.2. Objetivos específicos

- Configurar e validar um ambiente ROS 2 Humble sobre Ubuntu 22.04 em máquina virtual, com workspace Colcon e OpenCV integrados.
- Implementar um nó publisher que capture frames da webcam e os publique em /camera/image_raw no formato sensor_msgs/Image.
- Implementar um nó subscriber que aplique a conversão BGR→HSV e segmentação por cor, publicando a máscara resultante e a contagem de objetos segmentados.
- Disponibilizar o serviço /vision/status, que retorna sob demanda o número de objetos segmentados no último frame processado.
- Implementar o pipeline de visão computacional com detecção de faces (Haar Cascade) e extração de features (ORB/HOG) sobre os frames recebidos.
- Construir um dataset de no mínimo 300 imagens por espécie, a partir de acervos públicos de licença aberta complementados por imagens próprias.
- Treinar um classificador por transfer learning e integrá-lo como nó de inferência ROS 2, com resposta em tempo aceitável para operação interativa.
- Documentar a arquitetura implementada com diagrama de nós e tópicos e análise do grafo de comunicação gerado pelo rqt_graph.
- Entregar relatório em PDF, repositório GitHub versionado e vídeo de defesa de até 5 minutos.

4. Descrição do Produto e Funcionalidades Previstas

O produto final é um conjunto de pacotes ROS 2 que, executados em conjunto, formam um sistema de identificação de aracnídeos assistido por câmera. O usuário posiciona o exemplar (ou uma imagem dele) diante da webcam; o sistema exibe, em tempo real, a máscara de segmentação, as features extraídas e um painel com a identificação taxonômica e o grau de confiança da predição.

#	Funcionalidade	Descrição
F1	Aquisição contínua de imagem	Captura de frames da webcam Logitech 720p a uma taxa configurável e publicação em tópico ROS 2 padronizado.
F2	Segmentação por cor em HSV	Conversão do espaço de cor e aplicação de máscaras com limiares ajustáveis, com operações morfológicas para redução de ruído.
F3	Contagem de objetos	Detecção de contornos na máscara segmentada, com filtro por área mínima, e publicação da contagem.
F4	Serviço de status da visão	Serviço ROS 2 que retorna, sob requisição, o número de objetos segmentados no último frame e o instante do processamento.
F5	Detecção de faces	Detecção de faces humanas por classificador em cascata, atendendo ao requisito da disciplina e servindo de baseline comparativo para o

#	Funcionalidade	Descrição
		detector de aracnídeos.
F6	Extração de features	Extração de pontos de interesse e descritores (ORB) e de histogramas de gradientes orientados (HOG) sobre a região de interesse.
F7	Classificação de espécie	Inferência sobre a ROI segmentada, retornando a espécie mais provável entre as quatro do escopo e o grau de confiança.
F8	Resolução taxonômica	A partir da espécie predita, resolução da linhagem taxonômica completa, nome popular e características descritivas.
F9	Visualização e overlay	Sobreposição das informações sobre o frame original e publicação em tópico de imagem anotada.
F10	Introspecção da arquitetura	Geração do grafo de comunicação para análise e documentação da arquitetura.

5. Escopo

5.1. Está no escopo

- Reconhecimento de quatro espécies de aracnídeos, listadas na seção 7.4, mais uma classe negativa ("ausência de aracnídeo") para reduzir falsos positivos.
- Operação sobre imagem de webcam USB em tempo real e sobre arquivos de vídeo e imagens estáticas.
- Execução completa em máquina virtual Ubuntu 22.04 com ROS 2 Humble.
- Treinamento do modelo em ambiente externo (nuvem) e execução da inferência localmente na VM.
- Documentação, versionamento e vídeo de defesa conforme exigido pelo professor.

5.2. Está fora do escopo

A delimitação explícita do que não será feito é parte do compromisso técnico deste TAP:

- Identificação de espécies fora do conjunto definido - exemplares não pertencentes às quatro classes devem ser rejeitados por baixa confiança, não classificados forçadamente.
- Qualquer forma de aconselhamento médico, diagnóstico de acidente ou recomendação de tratamento. O sistema é uma ferramenta de identificação visual de caráter acadêmico e educacional, e essa limitação será declarada na interface e no relatório.
- Determinação de sexo, estágio de desenvolvimento ou medidas biométricas do exemplar.
- Manipulação física de exemplares vivos. O conjunto de imagens será construído a partir de acervos públicos e de fotografias de exemplares observados a distância segura, sem captura ou contenção de animais.
- Navegação autônoma, atuação mecânica ou controle de motores.

6. Requisitos

6.1. Requisitos funcionais

ID	Requisito	Prioridade
RF01	O sistema deve publicar frames capturados da câmera no tópico /camera/image_raw.	Obrigatório
RF02	O sistema deve converter os frames de BGR para HSV e aplicar segmentação por faixa de cor.	Obrigatório
RF03	O sistema deve expor o serviço /vision/status retornando a contagem de objetos do último frame.	Obrigatório
RF04	O sistema deve aplicar detecção de faces sobre os frames recebidos.	Obrigatório
RF05	O sistema deve extrair features dos frames e disponibilizá-las para inspeção.	Obrigatório
RF06	O sistema deve classificar a imagem entre as quatro espécies do escopo e a classe negativa.	Obrigatório
RF07	O sistema deve retornar: reino, filo, subfilo, classe, ordem, família, gênero, espécie, nome popular e características.	Obrigatório
RF08	O sistema deve informar o grau de confiança da predição e sinalizar predições abaixo do limiar.	Obrigatório
RF09	O sistema deve publicar um frame anotado com o resultado da identificação.	Desejável
RF10	O sistema deve permitir a substituição da fonte de imagem por arquivo de vídeo via parâmetro, sem alteração de código.	Desejável

6.2. Requisitos não funcionais

ID	Requisito	Critério
RNF01	A aquisição e publicação de imagem deve sustentar taxa mínima de operação interativa.	≥ 10 FPS a 640×480
RNF02	A inferência de classificação deve responder em tempo compatível com uso interativo em CPU.	≤ 500 ms por frame
RNF03	O sistema deve executar integralmente dentro da VM com recursos limitados.	4 GB RAM, 2 vCPU
RNF04	O código deve estar versionado com histórico de commits que evidencie a evolução por TP.	Repositório GitHub público
RNF05	Cada etapa de configuração e execução deve estar documentada com evidência visual.	Capturas de tela por etapa
RNF06	A arquitetura deve ser modular, com nós independentes e responsabilidade única.	Grafo com nós desacoplados
RNF07	O dataset deve utilizar apenas imagens com licença que permita uso acadêmico.	Licenças CC declaradas

7. Arquitetura Técnica Proposta

O sistema é decomposto em cinco nós ROS 2 com responsabilidade única, comunicando-se por tópicos e um serviço. Essa decomposição é o coração do projeto: cada nó pode ser executado, testado e substituído isoladamente.

7.1. Nós, tópicos e serviços

Nó	Tipo	Entrada	Saída
camera_node	Publisher	Dispositivo /dev/video0 ou arquivo de vídeo	/camera/image_raw (sensor_msgs/Image)
segmentation_node	Subscriber + Publisher + Server	/camera/image_raw	/vision/mask, /vision/object_count e serviço /vision/status
features_node	Subscriber + Publisher	/camera/image_raw	/vision/faces, /vision/features_image
classifier_node	Subscriber + Publisher	/camera/image_raw, /vision/mask	/aracne/identification (mensagem customizada)
overlay_node	Subscriber + Publisher	/camera/image_raw, /aracne/identification	/aracne/annotated_image

7.2. Interfaces customizadas

Será criado o pacote `aracne_interfaces` contendo a mensagem `SpiderID.msg` (campos: reino, filo, subfilo, classe, ordem, família, genero, especie, nome_popular, características, confiança, timestamp) e o serviço `VisionStatus.srv` (resposta: `object_count`, `last_frame_stamp`, `ok`). A definição de interfaces próprias, em vez do uso de mensagens genéricas do tipo `String`, é o que torna o sistema legível para outros nós e demonstra domínio do modelo de dados do ROS 2.

7.3. Estratégia de classificação e resolução taxonômica

Decisão de projeto relevante: o modelo de visão computacional não prediz a taxonomia completa. Ele prediz apenas a espécie. A linhagem taxonômica é determinística — dada a espécie, reino, filo, subfilo, classe, ordem, família e gênero são consequência lógica, não inferência. Fazer a rede aprender oito saídas correlacionadas seria desperdício de capacidade e fonte de inconsistência (o modelo poderia prever uma família incompatível com o gênero).

A arquitetura adotada é, portanto: a rede neural produz uma distribuição de probabilidade sobre cinco classes (quatro espécies e uma classe negativa); a espécie de maior probabilidade, se acima do limiar de confiança, é usada como chave em um arquivo `taxonomy.json` que devolve a linhagem completa, o nome popular e as características descritivas. Esse desacoplamento entre percepção e conhecimento simbólico é padrão em sistemas robóticos reais e será justificado no relatório.

O classificador será construído por transfer learning sobre uma rede pré-treinada leve (MobileNetV3-Small ou EfficientNet-B0), com congelamento do backbone e retreinamento da cabeça de classificação. O modelo será exportado em formato ONNX e executado na VM via `onnxruntime`, em CPU.

7.4. Espécies do escopo inicial

A seleção prioriza espécies brasileiras com boa disponibilidade de imagens em acervos públicos e, sobretudo, com separabilidade visual entre si — o que torna o problema tratável com um dataset pequeno. Todas compartilham a linhagem até a classe *Arachnida*, divergindo a partir da família:

Espécie	Nome popular	Família	Traço visual dominante
<i>Latrodectus curacaviensis</i>	Viúva-negra	Theridiidae	Abdome globoso escuro com marcas vermelhas
<i>Trichonephila clavipes</i>	Aranha-de-teia-dourada	Araneidae	Corpo alongado, pernas com tufo, seda dourada
<i>Lycosa erythrognatha</i>	Aranha-de-grama	Lycosidae	Corpo robusto acinzentado, quelíceras avermelhadas
<i>Avicularia avicularia</i>	Caranguejeira-rosa	Theraphosidae	Porte grande, pilosidade densa, extremidades claras

Linhagem comum a todas: Reino Animalia → Filo Arthropoda → Subfilo Chelicerata → Classe Arachnida → Ordem Araneae.

8. Stack Tecnológica e Ambiente

Camada	Tecnologia
Host	Fedora Linux (instalação nativa), 8 GB RAM
Virtualização	VMware Workstation Pro (padrão adotado na instituição)
Sistema convidado	Ubuntu 22.04 LTS - ISO fornecida pelo professor
Middleware robótico	ROS 2 Humble Hawksbill
Build system	Colcon, com workspace ~/aracne_ws
Visão computacional	OpenCV 4 (Python), cv_bridge
Aprendizado de máquina	PyTorch para treinamento (nuvem); ONNX Runtime para inferência (VM)
Linguagem	Python 3.10 (rclpy)
Câmera	Logitech C270 720p (USB), com passthrough para a VM
Hardware opcional	Raspberry Pi 3 - avaliação de viabilidade como nó remoto de aquisição
Versionamento	Git / GitHub
Gravação da defesa	OBS Studio ou Loom

Justificativa da divisão treinamento/inferência: com 8 GB de RAM no host e 4 GB alocados à VM, treinar uma rede convolucional localmente é inviável em tempo hábil. O treinamento será executado em ambiente de nuvem com GPU gratuita, e apenas o modelo exportado (poucos megabytes) retorna para a VM. Essa separação não é uma limitação contornada, mas a prática corrente em robótica: treina-se offline, embarca-se o modelo inferido.

9. Planejamento das Entregas (TP1 a TP5)

TP	Foco	Entregas previstas
TP1	Definição e planejamento	Este TAP; fundamentação da escolha do projeto; definição de

TP	Foco	Entregas previstas
		finalidade, aplicação prática e funcionalidades; planejamento das entregas seguintes; repositório GitHub inicializado.
TP2	Enunciado não liberado	Aguardando Liberação Enunciado
TP3	Enunciado não liberado	Aguardando Liberação Enunciado
TP4	Enunciado não liberado	Aguardando Liberação Enunciado
TP5	Enunciado não liberado	Aguardando Liberação Enunciado

Observação: o enunciado do TP5 ainda deve ser confirmado com o professor. O planejamento acima reserva para essa etapa a integração final e a validação quantitativa, que são o desfecho natural das quatro entregas anteriores, e será ajustado assim que o enunciado oficial for divulgado.

10. Cronograma e Disponibilidade

A disponibilidade para o projeto concentra-se fora do horário de trabalho (10h00 às 16h30, dias úteis), resultando em janelas de aproximadamente três horas em noites de dias úteis e blocos maiores aos fins de semana. O cronograma abaixo é dimensionado para essa realidade e prevê folga antes de cada entrega.

TP	Atividades	Esforço estimado	Janela de execução
TP1	Redação do TAP, pesquisa de referências, criação do repositório	6 a 8 h	Noites de dias úteis
TP2	Instalação da VM, ROS 2, workspace, OpenCV, validação e capturas	8 a 10 h	Um fim de semana
TP3	Nós publisher e subscriber, segmentação HSV, serviço, interfaces	12 a 15 h	Duas semanas, uso misto
TP4	Deteção de faces, extração de features, grafo e diagrama	10 a 12 h	Duas semanas, uso misto
TP5	Dataset, treinamento, integração, avaliação, relatório e vídeo	20 a 25 h	Fins de semana + reserva
—	Coleta incremental de imagens do dataset	4 a 6 h (diluídas)	Em paralelo, desde o TP2

Estratégia de paralelização: a construção do dataset é a atividade com maior risco de atraso e menor dependência técnica das demais. Por isso ela começa já no TP2 e avança em paralelo, evitando que o treinamento do modelo fique represado até o TP5.

11. Riscos e Plano de Mitigação

ID	Risco	Impacto	Mitigação
R1	Falha na compilação dos módulos de kernel do VMware sobre o kernel do Fedora,	Alto	Aplicar os módulos corrigidos da comunidade; se persistir, migrar para KVM/QEMU via virt-manager, nativo no Fedora, mantendo a mesma

ID	Risco	Impacto	Mitigação
	impedindo a virtualização.		ISO e o mesmo ambiente convidado.
R2	Memória insuficiente para treinar o modelo localmente.	Alto	Treinamento realizado em nuvem com GPU gratuita; apenas o modelo exportado é executado na VM.
R3	A webcam USB não é reconhecida dentro da máquina virtual.	Alto	Configurar passthrough USB e validar com v4l2-ctl antes do TP3; fallback documentado: publicação de vídeo pré-gravado pelo mesmo nó, via parâmetro.
R4	Dataset pequeno, desbalanceado ou com imagens de baixa qualidade.	Médio	Transfer learning sobre rede pré-treinada; aumento de dados; coleta iniciada no TP2; espécies escolhidas por separabilidade visual.
R5	Confusão entre espécies visualmente próximas.	Médio	Matriz de confusão como métrica de acompanhamento; exibição das três predições mais prováveis; limiar de confiança com rejeição explícita.
R6	Raspberry Pi 3 inoperante ou com desempenho insuficiente.	Baixo	A placa é item opcional; o escopo obrigatório é atendido integralmente pela webcam USB.
R7	Conflito entre a carga de trabalho profissional e os prazos de entrega.	Médio	Cronograma dimensionado para janelas noturnas; folga de uma semana antes de cada entrega; entregas parciais versionadas no GitHub.
R8	Perda de trabalho por corrupção da VM.	Médio	Commits frequentes no GitHub; snapshot da VM após cada marco concluído.

12. Critérios de Aceite

O projeto será considerado bem-sucedido se, ao final do TP5, os seguintes critérios forem verificáveis por demonstração:

ID	Critério	Verificação
CA01	O comando <code>ros2 doctor</code> executa sem erros críticos no ambiente configurado.	Captura de tela
CA02	O tópico <code>/camera/image_raw</code> publica imagens visualizáveis em <code>rqt_image_view</code> .	Demonstração ao vivo
CA03	A segmentação HSV produz máscara coerente e contagem de objetos consistente.	Demonstração ao vivo
CA04	O serviço <code>/vision/status</code> responde corretamente via <code>ros2 service call</code> .	Demonstração ao vivo
CA05	A detecção de faces e a extração de features operam sobre os frames recebidos.	Demonstração ao vivo
CA06	O grafo de comunicação exibe todos os nós e tópicos previstos na arquitetura.	Saída do <code>rqt_graph</code>
CA07	A acurácia do classificador no conjunto de teste é de ao menos 80%.	Matriz de confusão

ID	Critério	Verificação
CA08	A identificação retorna a taxonomia completa e as características da espécie.	Demonstração ao vivo
CA09	Todos os artefatos exigidos foram entregues no Moodle no formato solicitado.	Checklist de entrega

13. Premissas e Restrições

13.1. Premissas

- A ISO Ubuntu 22.04 fornecida pelo professor está íntegra e contém ou permite a instalação da distribuição ROS 2 Humble.
- Existem imagens de licença aberta em quantidade suficiente para as quatro espécies selecionadas.
- O hardware do notebook suporta virtualização assistida por hardware, habilitada na BIOS/UEFI.

13.2. Restrições

- 8 GB de RAM no host, limitando a alocação para a VM e inviabilizando treinamento local.
- Ausência de GPU dedicada disponível para o ambiente virtualizado.
- Disponibilidade concentrada em período noturno e fins de semana.
- Uso obrigatório de câmera e de ROS 2, conforme exigência da disciplina.
- Vídeo de defesa limitado a 5 minutos, com tela e webcam simultâneas.

14. Partes Interessadas

Parte	Papel	Interesse
Aluno	Executor e responsável técnico	Concluir as cinco entregas com qualidade e domínio demonstrável do conteúdo
Professor orientador	Aprovador e avaliador	Verificar aderência ao enunciado, profundidade técnica e clareza da documentação
Instituto Infnet	Instituição	Arquivamento institucional e conformidade acadêmica

15. Aprovação

Este Termo de Abertura formaliza o início do projeto ARACNE e estabelece escopo, objetivos, arquitetura, cronograma e critérios de aceitação acordados para as entregas TP1 a TP5.

Aluno responsável — João Rafael Broz dos Santos

Professor orientador — Dácio Moreira de Souza

Data: 28 / 08 / 2026